# **Proximal Gradient methods(continued)**

Chenglong Bao

YMSC, Tsinghua University

Acknowledgement: slides based on Prof. Lieven Vandenberghes and Prof. Zaiwen Wen (PKU).

### Inertial proximal algorithm

Consider the problem:

$$\min \quad f(x) = g(x) + h(x)$$

where  $\nabla q$  is L-Lipschitz.

- Choose  $x_0$  and set  $x_{-1} = x^0$ , choose  $\beta \in [0,1]$ , set  $\alpha < 2(1-\beta)/L$ and computes  $\chi_{\mathbf{k+1}} = \Pr \chi_{\mathbf{k}} \left( \chi_{\mathbf{k}} - \chi_{\mathbf{k}} \right) \left( \chi_{\mathbf{k}} - \chi_{\mathbf{k}} \right) \left( \chi_{\mathbf{k}} - \chi_{\mathbf{k}} \right)$   $x_{k+1} = \Pr \chi_{\alpha h} \left( x_k - \alpha \nabla g(x_k) + \beta (x_k - x_{k-1}) \right) \left( \chi_{\mathbf{k}} - \chi_{\mathbf{k}} \right).$ • The term  $\beta(x_k - x_{k-1}): \text{ inertial term } \chi_{\mathbf{k+1}} = \Pr \chi_{\mathbf{k}} \left( \chi_{\mathbf{k}} - \chi_{\mathbf{k}} \right).$
- For h=0, the scheme is referred as the Heavy ball method.
- Ref: P. Ochs, Y. Chen, T. Brox and T. Pock. IPiano: Inertial proximal algorithm for nonconvex optimization, SIAM J. Imaging Sciences, Vol

### Conditional gradient method: Motivation

Let  $\mathcal{X}$  be a compact set and consider

$$\min_{x \in \mathcal{X}} \quad f(x)$$

• Proximal gradient method:

eximal gradient method: 
$$x^{k+1} = \arg\min_{x \in \mathcal{X}} \left\{ f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2\alpha_k} \|x - x_k\|^2 \right\}$$

It is equivalent to the projected gradient method:

$$x_{k+1} = \mathcal{P}_{\mathcal{X}}(x_k - \alpha_k \nabla \underline{f(x_k)})$$

Difficulty: computation of the projection  $\mathcal{P}_{\mathcal{X}}(\cdot)$  may be expensive.

# Conditional gradient (CndG) or Frank-Wolfe method

Given  $y_0 = x_0$  and  $\alpha_k \in (0,1]$ , the CndG methods takes

• diminishing step sizes:

• Exact line search 
$$\nabla f(\mathbf{y}_{k-1}) = \mathbf{Z}_{k-1}$$

$$\alpha_k = \underset{\alpha \in [0,1]}{\operatorname{arg min}} f((1-\alpha)y_{k-1} + \alpha x_k)$$

$$\underset{\mathbf{x} \in \mathcal{X}}{\operatorname{min}} \left\langle \mathbf{Z}_{k-1}, \mathbf{x} \right\rangle \qquad \underset{\alpha \in [0,1]}{\operatorname{e}_{[0,1]}}$$

$$= - \underset{\mathbf{x}}{\operatorname{min}} \left\langle \mathbf{Z}_{k-1}, \mathbf{x} \right\rangle - \delta_{\mathbf{x}}(\mathbf{x})$$

$$= - \underbrace{S_{\mathbf{x}}^{*} \left( -2_{k-1} \right)}$$

# Examples

考虑带某一范数||.||约束的凸优化问题,

$$\min_{x} f(x) \quad \text{s.t.} \quad ||x|| \le t.$$

用条件梯度法求解该问题时,需要计算子问题,

$$x_{k} \in \underset{\|x\| \leq t}{\operatorname{argmin}} \langle \nabla f(y_{k-1}), x \rangle$$

$$= -t \cdot \left( \operatorname{argmax}_{\|x\| \leq 1} \langle \nabla f(y_{k-1}), x \rangle \right)$$

$$= -t \cdot \partial \|\nabla f(y_{k-1})\|_{*}. \tag{4}$$

其中 $\|z\|_* = \sup\{z^Tx, \|x\| \le 1\}$  是 $\|\cdot\|$  的对偶范数。注意到(4)条件梯度法的子问题相当于计算一个对偶范数的次梯度。如果计算 $\|\cdot\|$  范数的次梯度比计算在约束集合 $X = \{x \in \mathbb{R}^n: \|x\| \le t\}$  上的投影要简单,条件梯度法比投影梯度法效率更高。

## Examples: $\ell_1$ 范数约束问题

$$3||X|| = \{u| \langle u_2 x \rangle = ||X||, ||u||_{\#^{\leq 1}}\}$$

由于 $\ell_1$  范数的对偶范数是 $\ell_\infty$  范数,因此用条件梯度法求解该问题时子 问题为,

$$x_k \in -t \cdot \partial \|\nabla f(y_{k-1})\|_{\infty}.$$

 $x_k \in -t \cdot \partial \|\nabla f(y_{k-1})\|_{\infty}.$  考虑到 $\ell_{\infty}$  范数的次梯度为 $\partial \|x\|_{\infty} = \{v : \langle v, x \rangle = \|x\|_{\infty}, \|v\|_{1} \leq 1\},$  子 问题等价于,

$$\begin{cases} i_k \in \underset{i=1,\dots,n}{\operatorname{argmax}} |\nabla_i f(y_{k-1})| \\ x_k = -t \cdot \operatorname{sgn} [\nabla_{i_k} f(y_{k-1})] \cdot e_{i_k}. \end{cases}$$

其中 $\nabla_i f(y_{k-1})$  表示向量 $\nabla f(y_{k-1})$  的第i 个元素, $e_i$  表示第i 个元素为1 的单位向量。可以看到计算∥.∥∞的次梯度和计算集

 $合 X := \{x \in \mathbb{R}^n : ||x||_1 \le t\}$  上的投影都需要 $\mathcal{O}(n)$  的计算复杂度,但是 条件梯度法子问题计算明显要更简单直接。

# Examples: $\ell_p$ 范数约束问题, $1 \le p \le \infty$

由于 $\ell_p$  范数的对偶范数是 $\ell_q$  范数,其中1/p+1/q=1,因此用条件梯度法求解该问题时子问题为,

$$x_k \in -t \cdot \partial \|\nabla f(y_{k-1})\|_q$$
.

注意到 $\ell_q$  范数的次梯度为 $\partial \|x\|_q = \{v: \langle v, x \rangle = \|x\|_q, \|v\|_p \le 1\}$ ,子问题等价于,

$$x_k^{(i)} = -\beta \cdot \operatorname{sgn}\left[\nabla_i f(y_{k-1})\right] \cdot |\nabla_i f(y_{k-1})|^{p/q}.$$

其中 $\beta$  是使得 $\|x_k\|_q = t$  的归一化常数。可以看到,除过 $p = 1, 2, \infty$  这些特殊情形,条件梯度法的子问题计算复杂度比直接计算点在集合 $X = \{x \in \mathbb{R}^n: \|x\|_p \le t\}$  上的投影要简单,后者投影计算需要单独解一个优化问题。

# Example: 矩阵核范数约束优化问题

矩阵核范数||·||\*的对偶范数是其谱范数||·||2:

$$||X||_* = \sum_{i=1}^{\min\{m,n\}} \sigma_i(X), \qquad ||X||_2 = \max_{i=1,\dots,\min\{m,n\}} \sigma_i(X).$$

因此条件梯度法的子问题为 $X_k \in -t \cdot \partial \|\nabla f(Y_{k-1})\|_2$ . 对矩阵范数的次梯度:  $\partial \|X\| = \{Y: \langle Y, X \rangle = \|X\|, \|Y\|_* \leq 1\}$ ,设u, v 分别是矩阵 $\nabla f(Y_{k-1})$  最大奇异值对应的左、右奇异向量,注意到,

$$\langle uv^T, \nabla f(Y_{k-1})\rangle = u^T \nabla f(Y_{k-1})v = \sigma_{\max}(\nabla f(Y_{k-1})) = \|\nabla f(Y_{k-1})\|_2.$$

且 $\|uv^T\|_*=1$ ,因此矩阵 $uv^T\in\partial\|\nabla f(Y_{k-1})\|_2$ 。则条件梯度法子问题等价于,

$$X_k \in -t \cdot uv^T. \tag{5}$$

可以看到,条件梯度法计算子问题时只需要计算矩阵最大的奇异值对应的左、右奇异向量。如果采用投影梯度法,其子问题是计算X 到集合 $\{X\in\mathbb{R}^{m\times n}: \|X\|_*\leq t\}$  的投影,需要对矩阵做全奇异值分解,计算量比条件梯度法复杂很多。

# Convergence: Lemma

$$\Gamma_t = \begin{cases} 1 & t = 1 \\ (1 - \gamma_t)\Gamma_{t-1} & t \geq 2 \end{cases}$$
如果序列 $\{\Delta_t\}_{t \geq 0}$  满足
$$\sum_{\substack{j=1 \ 1-\gamma_1}} V \cdot \sum_{\substack{l-\gamma_1 \ 1-\gamma_1 \$$

f.-f\* 5 ... (f. f\*) +

### Convergence

Let f(x) is convex,  $\nabla f(x)$  is L-Lipschitz,  $D_X = \sup_{x,y \in X} \|x - y\|$ . Then

$$f(y_k) - f(x^*) \le \frac{2L}{k(k+1)} \sum_{i=1}^k ||x_i - y_{i-1}||^2 \le \underbrace{\frac{2L}{k+1} D_X^2}_{k}.$$

Proof: 
$$\diamondsuit \gamma_k = \frac{2}{k+1}$$
,记 $\bar{y}_k = (1 - \gamma_k)y_{k-1} + \gamma_k x_k$ ,则不管

$$\alpha_k = \frac{2}{k+1}$$
  $\not \propto \quad \alpha_k = \underset{\alpha \in [0,1]}{\operatorname{argmin}} f((1-\alpha)y_{k-1} + \alpha x_k).$ 

对
$$y_k = (1 - \alpha_k)y_{k-1} + \alpha_k x_k$$
, 我们都有 $\underline{f(y_k)} \leq f(\bar{y}_k)$ 。注意到 $\bar{y}_k - y_{k-1} = \gamma_k (x_k - y_{k-1})$ , 由 $f(x) \in C_L^{1,1}(X)$ 有

$$f(y_k) \le f(\bar{y}_k) \le \underline{f(y_{k-1})} + \langle \nabla f(y_{k-1}), \bar{y}_k - y_{k-1} \rangle + \frac{L}{2} ||\bar{y}_k - y_{k-1}||^2$$
 (6)

$$\leq (1 - \gamma_k)[f(y_{k-1}) + \gamma_k[f(y_{k-1}) + \langle \nabla f(y_{k-1}), x - y_{k-1} \rangle] + \frac{L\gamma_k^2}{2} ||x_k - y_{k-1}||^2$$
 (7)

$$\leq (1 - \gamma_k)f(y_{k-1}) + \gamma_k f(x) + \frac{L\gamma_k^2}{2} \|x_k - y_{k-1}\|^2, \quad \text{at } \notin \mathbb{R} x \in X.$$

$$\text{Subproble M.}$$
(8)

37/39

## Convergence

其中不等式(7) 是因为 $x_k \in \min_{x \in X} \langle \nabla f(y_{k-1}), x \rangle$ ,由最优性条件我们可 以得到对任意 $x \in X$  有 $\langle x - x_k, \nabla f(y_{k-1}) \rangle \ge 0$ 。将不等式(8) 稍做变换, 对任意 $x \in X$ ,

$$\underbrace{\frac{\int (y_k) - f(x)}{\Delta}}_{\Delta} \le (\underbrace{1 - \gamma_k}) [f(y_{k-1}) - f(x)] + \underbrace{\frac{L}{2} \gamma_k^2 \|x_k - y_{k-1}\|^2}_{\Delta}. \tag{9}$$

由引理可知,

$$\underbrace{f(y_k) - f(x)} \le \underbrace{\Gamma_k(1 - \gamma_1)[f(y_0) - f(x)]}_{} + \underbrace{\frac{\Gamma_k L}{2} \sum_{i=1}^{\kappa} \frac{\gamma_i^2}{\Gamma_i} ||x_i - y_{i-1}||^2}_{}.$$

由 $\gamma_k = \frac{2}{k+1}$ ,  $\gamma_1 = 1$  得到 $\Gamma_k = \frac{2}{k(k+1)}$ , 我们可以得到收敛性不等式,

$$f(y_k) - f^* \le \frac{2L}{k(k+1)} \sum_{i=1}^k ||x_i - y_{i-1}||^2 \le \frac{2L}{k+1} D_X^2.$$

令 $\frac{2L}{k+1}D_X^2 \leq \epsilon$ ,可以得到分析复杂度结论。

#### References

#### convergence analysis of proximal gradient method

- A. Beck and M. Teboulle, A fast iterative shrinkage-thresholding algorithm for linear inverse problems, SIAM Journal on Imaging Sciences (2009)
- A. Beck and M. Teboulle, *Gradient-based algorithms with applications to signal recovery*, in: Y. Eldar and D. Palomar (Eds.), *Convex Optimization in Signal Processing and Communications* (2009)