

应用统计

第5讲 参数点估计量的评价

点估计量的评价标准

1). 相合性 估计量随着样本量的增加而逼近参数的真实值。

定义: 设 $\theta \in \Theta$ 为未知参数, $\hat{\theta}_n = \hat{\theta}_n(x_1, x_2, \dots, x_n)$ 是由 n 个样本得到的 θ 的一个估计量, n 是样本容量, 若对任何 $\varepsilon > 0$, 有 $\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| > \varepsilon) = 0$ 则

称 $\hat{\theta}_n$ 为参数 θ 的相合估计。

依概率收敛, 也叫弱相合估计

定理: 设 $\hat{\theta}_n = \hat{\theta}_n(x_1, x_2, \dots, x_n)$ 是 θ 的一个估计量, 若

若是强相合估计则需要几乎处处收敛

$\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta$, $\lim_{n \rightarrow \infty} Var(\hat{\theta}_n) = 0$, 则 $\hat{\theta}_n$ 是参数 θ 的相合估计。

证明相合性的时候经常也会利用大数定律

相合性就是只要样本足够多, 就能保证估计尽可能的精确。

弱相合经常也会用Markov不等式来证明



点估计量的评价标准

2). 无偏性 保证没有系统偏差

设 $\theta \in \Theta$ 为未知参数, $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$ 是 θ 的一个估计量, 若对任意 $\theta \in \Theta$ 有 $E(\hat{\theta}) = \theta$, 则称 $\hat{\theta}$ 是参数 θ 的无偏估计。

3). 有效性 希望估计围绕参数波动的幅度越小越好。

设 $\hat{\theta}_1, \hat{\theta}_2$ 是参数 θ 的无偏估计, 如果对任意 $\theta \in \Theta$ 有 $Var(\hat{\theta}_1) \leq Var(\hat{\theta}_2)$, 且至少有一个 $\theta \in \Theta$ 使得上述不等号严格成立, 则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效。

简单的应用: 样本数量的增加会改善估计。



无偏性与有效性简单的练习

设总体 X 在区间 $[0, \theta]$ 上服从均匀分布，其中 $\theta > 0$ 未知。
从总体中抽取样本 X_1, X_2, X_3, X_4 ，则下列统计量均为 θ
的无偏估计量，比较它们的有效性

$$\hat{\theta}_1 = \frac{1}{2}(X_1 + X_2 + X_3 + X_4),$$

$$\hat{\theta}_2 = 2X_1 + X_2 - X_3,$$

$$\hat{\theta}_3 = X_1 + X_2 + X_3 - X_4$$

例 1 X_1, X_2, \dots, X_n 是来自均匀总体 $U(0, \theta)$ 的样本,

参数 θ 的矩估计量 $\hat{\theta}_1 = 2\bar{X}$, 极大似然估计量 $\tilde{\theta} = \max_{1 \leq k \leq n} X_k$, 考查无偏性。

$$E(\hat{\theta}_1) = E(2\bar{X}) = E(2X) = 2 \times \frac{\theta}{2} = \theta, \text{ 所以 } \hat{\theta}_1 = 2\bar{X} \text{ 是参数 } \theta \text{ 的无偏估计}$$

$$E(\tilde{\theta})?$$

计算 $\tilde{\theta} = \max_{1 \leq k \leq n} X_k$ 的分布函数,

当 $0 \leq y \leq \theta$ 时, 由样本的独立同分布性质, 可知其分布函数为

$$F_{\tilde{\theta}}(y) = P(\tilde{\theta} \leq y) = P\left(\max_{1 \leq k \leq n} X_k \leq y\right) = \prod_{k=1}^n P(X_k \leq y) = \left(\frac{y}{\theta}\right)^n$$

$$\tilde{\theta} = \max_{1 \leq k \leq n} X_k \text{ 的分布函数 } F_{\tilde{\theta}}(y) = \begin{cases} 0, y < 0 \\ \left(\frac{y}{\theta}\right)^n, 0 \leq y \leq \theta, \\ 1, y > \theta \end{cases}$$

于是 $\tilde{\theta}$ 的概率密度为 $f_{\tilde{\theta}}(y) = \begin{cases} \frac{n}{\theta^n} y^{n-1}, y \in [0, \theta] \\ 0, \text{其它} \end{cases}$, 因此, 我们有

$$\begin{aligned} E(\tilde{\theta}) &= \int_{-\infty}^{+\infty} y f_{\tilde{\theta}}(y) dy = \int_0^{\theta} y \frac{n}{\theta^n} y^{n-1} dy \\ &= \frac{n}{\theta^n} \int_0^{\theta} y^n dy = \frac{n}{\theta^n} \cdot \frac{y^{n+1}}{n+1} \Big|_0^{\theta} = \frac{n}{n+1} \theta \end{aligned}$$

$E(\tilde{\theta}) = E\left(\max_{1 \leq k \leq n} X_k\right) = \frac{n}{n+1}\theta$, 统计量 $\max_{1 \leq k \leq n} X_k$ 不是参数 θ 的无偏估计,

$\frac{n+1}{n} \max_{1 \leq k \leq n} X_k$ 则为无偏估计, 称为无偏校正。

例2 X_1, X_2, \dots, X_n 是来自均匀总体 $U(0, \theta)$ 的样本, $\hat{\theta}_1 = 2\bar{X}$ 和 $\hat{\theta}_2 = \frac{n+1}{n} \max_{1 \leq k \leq n} X_k$

都是参数 θ 的无偏估计, 比较它们的有效性。

解 均匀总体 $U(0, \theta)$ 的期望、方差分别为 $E(X) = \frac{\theta}{2}$, $Var(X) = \frac{\theta^2}{12}$

$$Var(\hat{\theta}_1) = Var(2\bar{X}) = 4Var(\bar{X}) = 4 \frac{Var(X)}{n} = 4 \frac{\theta^2}{12n} = \frac{\theta^2}{3n}$$

$$\hat{\theta}_2 = \frac{n+1}{n} \max_{1 \leq k \leq n} X_k ,$$

计算 $\tilde{\theta} = \max_{1 \leq k \leq n} X_k$ 的方差, $\tilde{\theta}$ 的概率密度为 $f_{\tilde{\theta}}(y) = \begin{cases} \frac{n}{\theta^n} y^{n-1}, y \in [0, \theta] \\ 0, \text{其它} \end{cases}$

$$E(\tilde{\theta}^2) = \int_0^{\theta} y^2 f_{\tilde{\theta}}(y) dy = \int_0^{\theta} y^2 \frac{n}{\theta^n} y^{n-1} dy$$

$$= \frac{n}{\theta^n} \int_0^{\theta} y^{n+1} dy = \frac{n}{\theta^n} \cdot \frac{\theta^{n+2}}{n+2} = \frac{n}{n+2} \theta^2 ,$$

$$Var(\tilde{\theta}) = E(\tilde{\theta}^2) - (E(\tilde{\theta}))^2 = \frac{n}{n+2} \theta^2 - \frac{n^2}{(n+1)^2} \theta^2 = \frac{n}{(n+1)^2 (n+2)} \theta^2$$

因此 $Var(\hat{\theta}_2) = Var\left(\frac{n+1}{n} \tilde{\theta}\right) = \frac{(n+1)^2}{n^2} Var(\tilde{\theta}) = \frac{1}{n(n+2)} \theta^2 .$

例2 X_1, X_2, \dots, X_n 是来自均匀总体 $U(0, \theta)$ 的样本, $\hat{\theta}_1 = 2\bar{X}$ 和 $\hat{\theta}_2 = \frac{n+1}{n} \max_{1 \leq k \leq n} X_k$

都是参数 θ 的无偏估计, 比较它们的有效性。

$$\text{Var}(\hat{\theta}_1) = \frac{\theta^2}{3n}, \quad \text{Var}(\hat{\theta}_2) = \frac{1}{n(n+2)} \theta^2$$

当 $n > 1$ 时, $\frac{1}{n(n+2)} \theta^2 < \frac{1}{3n} \theta^2$, 所以 $\hat{\theta}_2 = \frac{n+1}{n} \max_{1 \leq k \leq n} X_k$ 比 $\hat{\theta}_1 = 2\bar{X}$ 更有效。

例3 X_1, X_2, \dots, X_n 是来自均匀总体 $X \sim U(-a, a)$ 的样本, 用矩估计法估计参数 a 。

$$\text{Var}(X) = \frac{a^2}{3}, \quad \frac{a^2}{3} = s^2 \Rightarrow \hat{a} = \sqrt{3}s \quad \text{是不是 } a \text{ 的无偏估计?}$$

例4 设 X_1, X_2, \dots, X_n 是正态总体 $N(\mu, \sigma^2)$ 的样本, 求参数 μ 和 σ^2 的矩估计量和极大似然估计量。

解: $E(X) = \mu$, $Var(X) = \sigma^2$, 所以参数 μ 和 σ^2 的矩估计量为

$$\bar{\mu} = \bar{X}, \quad \bar{\sigma}^2 = S^2;$$

设 x_1, x_2, \dots, x_n 为样本观测值, 则似然函数

$$L(x; \mu, \sigma^2) = \prod_{k=1}^n f(x_k; \mu) = \prod_{k=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_k - \mu)^2}{2\sigma^2}} = \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2},$$

对数似然函数为

$$\ln L(x; \mu, \sigma^2) = \ln \left(\left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2} \right) = n \ln \left(\frac{1}{\sqrt{2\pi}} \right) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

将上式对 μ 求导，并令其等于 0

$$\frac{d \ln L(x; \mu, \sigma^2)}{d \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0$$

将上式对 σ^2 求导，并令其等于 0

$$\frac{d \ln L(x; \mu, \sigma^2)}{d \sigma^2} = -\frac{n}{2} \frac{1}{\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0$$

$$\text{解得 } \mu = \frac{x_1 + \cdots + x_n}{n} = \bar{x}, \quad \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

根据题意知必为对数似然函数的极大值点，

所以参数 μ 和 σ^2 的极大似然估计量为 $\hat{\mu} = \bar{X}$, $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$

4). 均方误差 平均偏差

参数 θ 的估计量无偏估计 $\hat{\theta}$ 的均方误差 (mean squared error, 简记为 MSE), 是由 $E((\hat{\theta} - \theta)^2)$ 定义的关于 θ 的函数

$$E((\hat{\theta} - \theta)^2) = \text{Var}(\hat{\theta}) - \left(E(\hat{\theta}) - \theta\right)^2$$

例 5 设 X_1, X_2, \dots, X_n 是正态总体 $N(\mu, \sigma^2)$ 的样本, 计算例 4 中关于参数 μ 和 σ^2 的矩估计量和极大似然估计量的 MSE。

参数 μ 和 σ^2 的矩估计量为 $\bar{\mu} = \bar{X}$, $\bar{\sigma}^2 = S^2$

参数 μ 和 σ^2 的极大似然估计量为 $\hat{\mu} = \bar{X}$, $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$

$$E\left((\hat{\sigma}^2 - \sigma^2)^2\right) < E\left((\bar{\sigma}^2 - \sigma^2)^2\right)$$



均方误差 (Mean square error, MSE)

例 5 设 X_1, X_2, \dots, X_n 是正态总体 $N(\mu, \sigma^2)$ 的样本, 计算例 4 中关于参数 μ 和 σ^2 的矩估计量和极大似然估计量的 MSE。

参数 μ 和 σ^2 的矩估计量为 $\bar{\mu} = \bar{X}$, $\bar{\sigma}^2 = S^2$

$$E\left((\bar{\mu} - \mu)^2\right) = E\left((\bar{X} - \mu)^2\right) = \text{Var}(\bar{X}) = \frac{\sigma^2}{n}$$

$$\frac{(n-1) \cdot S^2}{\sigma^2} \sim \chi^2(n-1)$$

$$E\left((\bar{\sigma}^2 - \sigma^2)^2\right) = E\left((S^2 - \sigma^2)^2\right) \stackrel{E(S^2)=\sigma^2}{=} \text{Var}(S^2) = \frac{2\sigma^4}{n-1}$$

参数 μ 和 σ^2 的矩估计量为 $\bar{\mu} = \bar{X}$, $\bar{\sigma}^2 = S^2$

参数 μ 和 σ^2 的极大似然估计量为 $\hat{\mu} = \bar{X}$, $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{n-1}{n} S^2$

$$\begin{aligned} E\left(\left(\frac{n-1}{n} S^2 - \sigma^2\right)^2\right) &= E\left(\left(\frac{n-1}{n} (S^2 - \sigma^2) - \frac{1}{n} \sigma^2\right)^2\right) \\ &= \left(\frac{n-1}{n}\right)^2 E\left((S^2 - \sigma^2)^2\right) - 2E\left(\frac{n-1}{n} (S^2 - \sigma^2) \cdot \frac{1}{n} \sigma^2\right) + \frac{1}{n^2} \sigma^4 \\ &\stackrel{E(S^2)=\sigma^2}{=} \left(\frac{n-1}{n}\right)^2 \text{Var}(S^2) + \frac{1}{n^2} \sigma^4 \\ &= \left(\frac{n-1}{n}\right)^2 \frac{2\sigma^4}{n-1} + \frac{1}{n^2} \sigma^4 = \frac{2n-1}{n^2} \sigma^4 \\ E\left(\left(\hat{\sigma}^2 - \sigma^2\right)^2\right) &= \frac{2n-1}{n^2} \sigma^4 < \frac{2}{n-1} \sigma^4 = E\left(\left(\bar{\sigma}^2 - \sigma^2\right)^2\right) \end{aligned}$$

例 6 设 X_1, X_2, \dots, X_n 是二项总体 $b(1, p)$ 的样本, 考虑如下两个关于参数 p 的估





计量的 MSE, $\hat{p}_1 = \bar{X}$, $\hat{p}_2 = \frac{n\bar{X} + \alpha}{\alpha + \beta + n}$ 。

$$E\left((\hat{p}_1 - p)^2\right) = \text{Var}(\bar{X}) = \frac{p(1-p)}{n}$$

$$E\left((\hat{p}_2 - p)^2\right) = \text{Var}(\hat{p}_2) + \left(E(\hat{p}_2) - p\right)^2 = \text{Var}\left(\frac{n\bar{X} + \alpha}{\alpha + \beta + n}\right) + \left(\frac{np + \alpha}{\alpha + \beta + n} - p\right)^2$$

$$= \frac{np(1-p)}{(\alpha + \beta + n)} + \left(\frac{np + \alpha}{\alpha + \beta + n} - p\right)^2$$

$$\text{当 } \alpha = \beta = \frac{\sqrt{n}}{2} \text{ 时, } \hat{p}_2 = \frac{n\bar{X} + \sqrt{n}/2}{n + \sqrt{n}}, \quad E\left((\hat{p}_2 - p)^2\right) = \frac{n}{4(n + \sqrt{n})^2}$$





最小方差无偏估计

(Minimum Variance Unbiased, MVU)

定义 设 $\hat{\theta}$ 为 $g(\theta)$ 的无偏估计, 若对 $g(\theta)$ 的任何无偏估计 $\hat{\theta}_1$, $Var_{\theta}(\hat{\theta}) \leq Var_{\theta}(\hat{\theta}_1)$ 对 θ 的任何可能的值都成立, 则称 $\hat{\theta}$ 为 $g(\theta)$ 的一个最小方差无偏估计 (MVU 估计)。

克拉美-劳不等式 (Cramer-Rao) 满足一定条件, $T = T(x_1, x_2, \dots, x_n)$ 是 $g(\theta)$ 的任一无偏估计, 有 $Var(T) \geq \frac{(g'(\theta))^2}{nI(\theta)}$, 其中 $I(\theta) = E\left[\left(\frac{\partial}{\partial \theta} \ln p(x; \theta)\right)^2\right]$, 称为 Fisher 信息量, n 是样本容量。



克拉美-劳不等式成立条件

设总体概率函数 $p(x; \theta)$, $\theta \in \Theta$ 满足下列条件

1. 参数空间 Θ 是直线上的一个开区间;

2. 支撑集 $S = \{x : p(x; \theta) > 0\}$ 与 θ 无关;

3. 对一切 $\theta \in \Theta$, $\frac{\partial}{\partial \theta} p(x; \theta)$ 存在;

4. 对 $p(x; \theta)$, 积分与微分运算的次序可以交换, 即

$$\frac{\partial}{\partial \theta} \int_{-\infty}^{+\infty} p(x; \theta) dx = \int_{-\infty}^{+\infty} \frac{\partial}{\partial \theta} p(x; \theta) dx ;$$

5. 期望 $E \left(\left(\frac{\partial}{\partial \theta} \ln p(x; \theta) \right)^2 \right)$ 存在

克拉美-劳不等式 (Cramer-Rao) 满足一定条件, $T = T(x_1, x_2, \dots, x_n)$ 是 $g(\theta)$ 的任一无偏估计, 有 $Var(T) \geq \frac{(g'(\theta))^2}{nI(\theta)}$, 其中 $I(\theta) = E\left(\left(\frac{\partial}{\partial\theta} \ln p(x; \theta)\right)^2\right)$, 称为 Fisher 信息量, n 是样本容量。

$$\int_{-\infty}^{+\infty} p(x_k; \theta) dx_k = 1 \Rightarrow \frac{\partial}{\partial\theta} \int_{-\infty}^{+\infty} p(x_k; \theta) dx_k = \int_{-\infty}^{+\infty} \frac{\partial}{\partial\theta} p(x_k; \theta) dx_k = 0$$

$$\int_{-\infty}^{+\infty} \frac{\partial}{\partial\theta} p(x_k; \theta) dx_k = \int_{-\infty}^{+\infty} \left[\frac{\partial}{\partial\theta} \ln p(x_k; \theta) \right] p(x_k; \theta) dx_k = E\left(\frac{\partial}{\partial\theta} \ln p(X_k; \theta)\right) = 0$$

$$\text{记 } Z = \frac{\partial}{\partial\theta} \ln\left(\prod_{k=1}^n p(X_k; \theta)\right) = \sum_{k=1}^n \frac{\partial}{\partial\theta} \ln p(X_k; \theta)$$

$$\text{则 } E(Z) = \sum_{k=1}^n E\left(\frac{\partial}{\partial\theta} \ln p(X_k; \theta)\right) = 0$$

$$E(Z^2) = Var(Z) = \sum_{k=1}^n Var\left(\frac{\partial}{\partial\theta} \ln p(X_k; \theta)\right) = \sum_{k=1}^n E\left(\left(\frac{\partial}{\partial\theta} \ln p(X_k; \theta)\right)^2\right) = nI(\theta)$$

$$g(\theta) = \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} T(x_1, x_2, \dots, x_n) \prod_{k=1}^n p(x_k; \theta) dx_1 dx_2 \cdots dx_n$$

$$g'(\theta) = \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} T(x_1, x_2, \dots, x_n) \frac{\partial}{\partial \theta} \prod_{k=1}^n p(x_k; \theta) dx_1 dx_2 \cdots dx_n$$

$$= \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} T(x_1, x_2, \dots, x_n) \left[\frac{\partial}{\partial \theta} \ln \left(\prod_{k=1}^n p(x_k; \theta) \right) \right] \prod_{k=1}^n p(x_k; \theta) dx_1 dx_2 \cdots dx_n$$

$$= E \left(T(X_1, X_2, \dots, X_n) \frac{\partial}{\partial \theta} \ln \left(\prod_{k=1}^n p(X_k; \theta) \right) \right) = E(T \cdot Z)$$

$$g'(\theta) = E(T \cdot Z) = E((T - g(\theta)) \cdot Z) = \text{Cov}(T - g(\theta), Z)$$

$$[g'(\theta)]^2 \leq E((T - g(\theta))^2) \cdot E(Z^2) = \text{Var}(T) \cdot \text{Var}(Z) \Rightarrow \text{Var}(T) \geq \frac{(g'(\theta))^2}{nI(\theta)}$$



Fisher信息量

Fisher 信息量：

$$I(\theta) = E \left[\frac{\partial}{\partial \theta} \ln p(x; \theta) \right]^2 = E \left[\frac{\left(\frac{\partial}{\partial \theta} p(x; \theta) \right)}{p(x; \theta)} \right]^2 = \int \left[\frac{\left(\frac{\partial}{\partial \theta} p(x; \theta) \right)^2}{p(x; \theta)} \right] dx。$$

Fisher 信息量 $I(\theta)$ 越大，克拉美-劳不等式中的下界越低，表示 $g(\theta)$ 的无偏估计更有可能达到较小的方差，即更有可能被估计的准确一些。

$g(\theta)$ 的估计完全来自于样本， $g(\theta)$ 能估得更准，表示样本所含的信息量更大。 n 是样本数目，如把总信息看做分母 $nI(\theta)$ ，则一个样本恰好占有信息量 $I(\theta)$ 。 $I(\theta)$ 越大意味着参数越容易估计，它反映模型“易于认识”的程度。这个量在统计学中有多方面重要的应用。

最小方差无偏估计 (MVU) 的判断

例 1. 设样本 X_1, X_2, \dots, X_n 来自指数总体 $Exp(\lambda)$, 估计其期望 $g(\lambda) = \frac{1}{\lambda}$ 。

$$E(\bar{X}) = g(\lambda) = \frac{1}{\lambda}, \quad Var(\bar{X}) = \frac{1}{n\lambda^2}, \quad g'(\lambda) = -\frac{1}{\lambda^2}$$

$$(g'(\lambda))^2 = \frac{1}{\lambda^4},$$

$$I(\lambda) = E\left[\left(\frac{\partial}{\partial \lambda} \ln p(X; \lambda)\right)^2\right] = E\left[\left(\frac{\partial}{\partial \lambda} \ln(\lambda e^{-\lambda X})\right)^2\right] = E\left[\left(\frac{1}{\lambda} - X\right)^2\right] = \frac{1}{\lambda^2}$$

$$\frac{(g'(\lambda))^2}{nI(\lambda)} = \frac{1}{n\lambda^2} = Var(\bar{X})$$

最小方差无偏估计 (MVU) 的判断

例 2. 设样本 X_1, X_2, \dots, X_n 来自泊松总体 $P(\lambda)$, 估计其期望 $g(\lambda) = \lambda$

$$E(\bar{X}) = \lambda, \quad \text{Var}(\bar{X}) = \frac{\lambda}{n}, \quad E(S^2) = \lambda, \quad \text{Var}(S^2) = ?$$

$$(g'(\lambda))^2 = 1,$$

$$I(\lambda) = E \left[\left(\frac{\partial}{\partial \lambda} \ln \left(e^{-\lambda} \frac{\lambda^X}{X!} \right) \right)^2 \right] = E \left[\left(\frac{X}{\lambda} - 1 \right)^2 \right] = \frac{1}{\lambda}$$

$$\frac{(g'(\lambda))^2}{nI(\lambda)} = \frac{\lambda}{n} = \text{Var}(\bar{X})$$

最小方差无偏估计 (MVU) 的判断

例 3. 设样本 X_1, X_2, \dots, X_n 来自正态总体 $N(\mu, \sigma^2)$, σ^2 已知, 估计 μ

$$p(x; \mu) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2\sigma^2}(x - \mu)^2\right],$$

$$I(\mu) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\infty} \frac{(x - \mu)^2}{\sigma^4} \exp\left[-\frac{1}{2\sigma^2}(x - \mu)^2\right] dx = \frac{1}{\sigma^4} \sigma^2 = \frac{1}{\sigma^2}$$

按照克拉美-劳不等式, 参数 μ 的无偏估计量方差的下界为 $\frac{(g'(\mu))^2}{nI(\mu)} = \frac{\sigma^2}{n}$,

\bar{X} 是 μ 的无偏估计, 方差恰好为 $Var(\bar{X}) = \frac{\sigma^2}{n}$, 因此 \bar{X} 是 μ 的 MVU 估计。



无偏估计的改善

定理 设 X 、 Y 是两个随机变量, $E(X) = \mu$, $Var(X) > 0$, 令 $\varphi(y) = E(X|Y = y)$, 则有 $E(\varphi(Y)) = \mu$, $Var(\varphi(Y)) \leq Var(X)$, 其中等号成立的充分必要条件是 X 与 $\varphi(Y)$ 几乎处处相等。

$$E(X) = E(E(X|Y)), \quad Var(X) = Var(E(X|Y)) + E(Var(X|Y))$$

其中等号成立的充分必要条件是 X 与 $E(X|Y)$ 几乎处处相等。

Rao-Blackwell 定理 设总体的概率密度函数为 $p(x; \theta)$, x_1, x_2, \dots, x_n 是其样本。 $T = T(x_1, \dots, x_n)$ 是 θ 的充分统计量, 则对 θ 的任意无偏估计 $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$, $\tilde{\theta} = E(\hat{\theta}|T)$ 也是 θ 的无偏估计, 且 $Var(\tilde{\theta}) \leq Var(\hat{\theta})$ 。



充分统计量

- 统计量是把样本中的信息进行加工处理的结果，它可简化数据规律，便于统计推断。人们自然希望这种加工处理不损失原样本的信息。包含关于未知参数全部信息的统计量就叫充分统计量。

1920 年，R. A. Fisher 与天文学家 Eddington 之间有一场争论。

Eddington 用 $D = \sqrt{\frac{\pi}{2}} \frac{1}{n} \sum_{i=1}^n |X_i - \bar{X}|$ 估计正态总体 $N\left(\mu, \frac{\sigma^2}{n}\right)$ 的标准差 σ ，Fisher

主张用 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 中的 S 。Fisher 的理由是： S 包含了有关 σ 的全

部信息，而 D 则不是。因为只要算出 S 这个统计量的值，就是把原信息丢掉，对参数 σ 的估计也无任何损失。

定义 设 X_1, X_2, \dots, X_n 是来自某个总体的样本, 总体分布函数为 $F(x; \theta)$, 统计量 $T = T(X_1, X_2, \dots, X_n)$ 称为 θ 的充分统计量, 如果在给定 T 的取值后, X_1, X_2, \dots, X_n 的条件分布与 θ 无关。

例 1. 设 X_1, X_2, \dots, X_n 来自总体 $b(1, p)$, 则 $T = n\bar{X}$ 是参数 p 的充分统计量。

$$\begin{aligned}
 & P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n | T = t) \\
 &= \frac{P\left(X_1 = x_1, X_2 = x_2, \dots, X_n = t - \sum_{k=1}^{n-1} x_k\right)}{P(T = t)} = \frac{\prod_{k=1}^{n-1} P(X_k = x_k) \cdot P\left(X_n = t - \sum_{k=1}^{n-1} x_k\right)}{\binom{n}{t} p^t (1-p)^{n-t}} \\
 &= \frac{\prod_{k=1}^{n-1} p^{x_k} (1-p)^{1-x_k} \cdot p^{t - \sum_{k=1}^{n-1} x_k} (1-p)^{1 - (t - \sum_{k=1}^{n-1} x_k)}}{\binom{n}{t} p^t (1-p)^{n-t}} = \frac{p^t (1-p)^{n-t}}{\binom{n}{t} p^t (1-p)^{n-t}} = \frac{1}{\binom{n}{t}}
 \end{aligned}$$

例 1. 设 X_1, X_2, \dots, X_n 来自总体 $b(1, p)$,

若 $T = X_1 + X_2$,

$$\begin{aligned} & P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n | T = t) \\ &= \frac{P(X_1 = x_1, X_2 = t - x_2, \dots, X_n = x_n)}{P(X_1 + X_2 = t)} \\ &= \frac{p^{t+x_3+\dots+x_n} (1-p)^{n-t-(x_3+\dots+x_n)}}{\binom{2}{t} p^t (1-p)^{2-t}} = \frac{p^{x_3+\dots+x_n} (1-p)^{n-2-(x_3+\dots+x_n)}}{\binom{2}{t}} \end{aligned}$$



充分统计量的判定

因子分解定理 设总体的**概率函数**为 $F(x; \theta)$, X_1, X_2, \dots, X_n 为样本, 则

$T = T(X_1, X_2, \dots, X_n)$ 为 θ 的充分统计量的充分必要条件是: 存在两个函数

$g(t, \theta)$ 和 $h(x_1, x_2, \dots, x_n)$ 使得对任意的 θ 和任一组观察值 x_1, x_2, \dots, x_n , 有

$f(x_1, x_2, \dots, x_n; \theta) = g(T(x_1, x_2, \dots, x_n), \theta) \cdot h(x_1, x_2, \dots, x_n)$, 其中 $g(t, \theta)$ 是通过统计量 T 的取值而依赖于样本的。(概率函数是指密度函数或概率分布列)

例 2. 设 X_1, X_2, \dots, X_n 来自正态总体 $N(\mu, \sigma^2)$, 则 (\bar{X}, S^2) 是参数 $\theta = (\mu, \sigma^2)$ 的充分统计量。

$$\begin{aligned} p(x_1, x_2, \dots, x_n; \mu, \sigma^2) &= \frac{1}{(2\pi)^{\frac{n}{2}} \sigma^n} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right) \\ &= \frac{1}{(2\pi)^{\frac{n}{2}} \sigma^n} \exp\left(-\frac{n}{2\sigma^2} (\bar{x} - \mu)^2\right) \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \bar{x})^2\right) \\ &= \frac{1}{(2\pi)^{\frac{n}{2}} \sigma^n} \exp\left(-\frac{n}{2\sigma^2} (\bar{x} - \mu)^2\right) \exp\left(-\frac{(n-1)s^2}{2\sigma^2}\right) \end{aligned}$$



无偏估计的改善

例 1. 设 X_1, X_2 来自正态总体 $N(\mu, 1)$, $\bar{X} = \frac{X_1 + X_2}{2}$, $E(\bar{X}) = \mu$, $Var(\bar{X}) = \frac{1}{2}$

定义 $\varphi(X_1) = E(\bar{X} | X_1)$, 则

$$E(E(\bar{X} | X_1)) = E(\bar{X}) = \mu, \quad Var(E(\bar{X} | X_1)) \leq Var(\bar{X})$$

$$\varphi(X_1) = E(\bar{X} | X_1) = E\left(\frac{X_1 + X_2}{2} | X_1\right)$$

$$= \frac{1}{2}E(X_1 | X_1) + \frac{1}{2}E(X_2 | X_1) = \frac{1}{2}X_1 + \frac{1}{2}\mu$$

无偏估计的改善

例 2. 设有某商场顾客到来服从泊松分布，即每分钟到达的人数服从参数为 λ 泊松分布， X_1, X_2, \dots, X_n 为一个样本，分别记录连续 n 分钟观察到的每分钟顾客到达的人数。希望估计每分钟没有顾客到来的概率 $e^{-\lambda}$ 。

$$\theta_0 = \begin{cases} 1 & \text{if } x_1 = 0 \\ 0 & \text{otherwise} \end{cases} \quad \text{为参数 } e^{-\lambda} \text{ 的一个无偏估计量,}$$

$$S_n = \sum_{k=1}^n X_k \text{ 是 } \lambda \text{ 的充分统计量,}$$

取充分统计量下的条件期望保证仍然是统计量

$$\theta_1 = E(\theta_0 | S_n) = \left(1 - \frac{1}{n}\right)^{S_n} \text{ 为 } e^{-\lambda} \text{ 改进的无偏估计量。}$$



作业

习题二

15, 18, 19

其中19题第一问利用讲义方法构造并给出改进

补充题, 已知 X_1, X_2, \dots, X_n 为总体 $X \sim \text{Exp}(\lambda)$ 的样本, $E(X) = \frac{1}{\lambda}$ 。

\bar{X} 为样本均值, 用 $\frac{1}{\bar{X}}$ 估计参数 λ 是否为无偏估计, 给出解释。