

《线性回归》 —线性回归(6)

杨 瑛

清华大学 数学科学系

Email: yangying@mail.tsinghua.edu.cn

Tel: 62796887

2019.03.28

主要内容：LSE的性质

- σ^2 的无偏估计
- 分布理论
- MLE

σ^2 的无偏估计

- ♠ 假定误差满足条件: $\epsilon_i \sim (0, \sigma^2)$, 或者 $\epsilon_i \text{ iid } N(0, \sigma^2)$, 则为推断的缘故, 需要估计 σ^2 .
- ♠ 通常利用残差 $\hat{\epsilon}_i$ 来估计

Theorem

假设 $\mathbf{E}[\mathbf{Y}] = \mathbf{X}\theta$, \mathbf{X} 是 $n \times p$ 的秩为 r ($r \leq p$) 的矩阵, $\text{Var}[\mathbf{Y}] = \sigma^2 \mathbf{I}_n$, 则

$$s^2 = \frac{(\mathbf{Y} - \hat{\mathbf{Y}})^T (\mathbf{Y} - \hat{\mathbf{Y}})}{n - r} = \frac{SSE}{n - r}$$

是 σ^2 的无偏估计, $\hat{\mathbf{Y}} = \mathbf{Y} - \mathbf{X}\hat{\theta}$ 为残差, SSE 是残差平方和.

证明:

考虑满秩的表示 $V = \mathbf{X}_1\alpha$, 其中 \mathbf{X}_1 是秩为 r 的 $n \times r$ 矩阵, 则

$$\mathbf{Y} - \hat{\mathbf{Y}} = (\mathbf{I}_n - P)\mathbf{Y},$$

其中 α 是 $r \times 1$ 的列向量, $P = \mathbf{X}_1(\mathbf{X}_1^T\mathbf{X}_1)^{-1}\mathbf{X}_1^T$. 从而,

$$\begin{aligned}(n-r)S^2 &= \mathbf{Y}^T(\mathbf{I}_n - P)^T(\mathbf{I}_n - P)\mathbf{Y} \\ &= \mathbf{Y}^T(\mathbf{I}_n - P)\mathbf{Y} \\ &= \mathbf{Y}^T(\mathbf{I}_n - P)\mathbf{Y}.\end{aligned}$$

注意到 P 是投影矩阵, 估计 $PV = V$, 由此

$$\begin{aligned}\mathbf{E}[\mathbf{Y}^T(\mathbf{I}_n - P)\mathbf{Y}] &= \sigma^2\text{tr}(\mathbf{I}_n - P) + V^T(\mathbf{I}_n - P)V \\ &= \sigma^2(n-r),\end{aligned}$$

即, $\mathbf{E}[S^2] = \sigma^2$.

说明:

- ♠ 当 \mathbf{X} 是满秩时, $S^2 = (\mathbf{Y} - \mathbf{X}\hat{\theta})^T(\mathbf{Y} - \mathbf{X}\hat{\theta})/(n - p)$.
- ♠ 而且在略强的条件之下, $(n - p)S^2$ 是 $(n - p)\sigma^2$ 的唯一的非负无偏方差估计. 详见Seber and Lee (2003) Theorem 3.4 (Atiqullah, 1962) p. 45. 研究的是 σ^2 在一定意义下的最优估计.
- ♠ Gauss-Markov定理表明, 最小二乘估计 $\hat{\theta}$ 是一个不错的选择, 但如果误差相关或方差不等, 则可能会有更好的估计. 在误差是非正态时, 非线性或有偏估计在某种意义上可能会有更好的表现. 所以这个定理并没有告诉一个人一直要使用最小二乘法, 它只是强烈暗示它, 除非有一些强有力的理由不这样做.

说明: (续)

- ♠ 考虑使用除普通最小二乘以外的估计的情况是:
 - ✓ 当误差相关或具有不等方差时, 应使用广义最小二乘法.
 - ✓ 当错误分布是长尾时, 可能会使用稳健估计. 稳健的估计通常关于 \mathbf{Y} 是非线性的.
 - ✓ 当预测变量高度相关 (共线) 时, 可能更倾向于使用诸如岭回归之类的有偏估计.

分布理论

♠ 在更强的条件 $\epsilon \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n)$ 之下，我们有

Theorem

如果 $\mathbf{Y} \sim N_n(\mathbf{X}\theta, \sigma^2 \mathbf{I}_n)$, \mathbf{X} 是 $n \times p$ 的秩为 p 的矩阵。则

- (i) $\hat{\theta} \sim N_p(\theta, \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1})$.
- (ii) $(\hat{\theta} - \theta)^T \mathbf{X}^T \mathbf{X} (\hat{\theta} - \theta) / \sigma^2 \sim \chi_p^2$.
- (iii) $\hat{\theta}$ 与 S^2 独立.
- (iv) $SSE / \sigma^2 = (n - p) S^2 / \sigma^2 \sim \chi_{n-p}^2$.

证明参见 Seber and Lee, p. 48

定理的用处:

♠ 可以用于检验假设【后续还要讲】

$$H_0 : \theta_1 = \cdots = \theta_p = 0,$$

或者

$$H_{0j} : \theta_j = 0, j = 1, \cdots, p,$$

等等。

MLE

考虑线性模型

$$\mathbf{Y} = \mathbf{X}\theta + \epsilon, \epsilon \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n),$$

其中 \mathbf{X} 是秩为 p 的 $n \times p$ 的设计矩阵。参数 θ 和 σ^2 可以通过最大似然方法得到。

由于

$$\mathbf{Y} \sim N_n(\mathbf{X}\theta, \sigma^2 \mathbf{I}_n),$$

故似然函数为：

$$L(\theta, \sigma^2 | \mathbf{X}, \mathbf{Y}) = (2\sigma^2)^{-n/2} \exp \left\{ -\frac{\|\mathbf{Y} - \mathbf{X}\theta\|^2}{2\sigma^2} \right\}.$$

经常是先做出似然函数，然后再加上一些惩罚

说明:

- ♠ θ 和 σ^2 的MLE求法类似《统计推断》课程中正态分布总体参数的MLE的求法. 详见Seber and Lee (2003), p. 49–50
- ♠ 特别注意: $\hat{\theta}_{LSE} = \hat{\theta}_{MLE}$, 但是 σ^2 的估计为:

$$\hat{\sigma}^2 = \frac{1}{n} \|\mathbf{Y} - \mathbf{X}\hat{\theta}\|^2$$

是 σ^2 的有偏估计。

σ^2 的无偏估计是:

$$S^2 = \frac{1}{n-p} \|\mathbf{Y} - \mathbf{X}\hat{\theta}\|^2,$$

其中 $p = \dim(\theta)$ (为 θ 的维数).

思考题：

考虑线性模型

$$\mathbf{Y} = \mathbf{X}\theta + \epsilon, \epsilon \sim N_n(\mathbf{0}, \sigma^2 \Sigma),$$

其中 \mathbf{X} 是秩为 p 的 $n \times p$ 的设计矩阵, θ 和 σ^2 是未知的, Σ 是已知的 $n \times n$ 的正定矩阵。

- ♠ 试讨论 θ 和 σ^2 的MLE以及 θ 的LSE, 以及基于LSE的 σ^2 的估计
- ♠ 试研究这些估计的性质 (例如, 无偏性, 相合性, 分布, 相对效率等)

作业:

考虑线性模型

$$\mathbf{Y}_i = \mathbf{X}_i^T \theta + \epsilon_i, \epsilon_1, \dots, \epsilon_n \sim iid U(-\sigma, \sigma),$$

其中 \mathbf{X} 是列满秩, θ 和 σ^2 是未知的. 试研究参数 θ 和 σ 的LSE和MLE的性质[包括无偏性, 相合性和渐近正态性等]

【第十讲结束】