

《线性回归》 —线性回归(7)

杨 瑛

清华大学 数学科学系

Email: yangying@mail.tsinghua.edu.cn

Tel: 62796887

2019.03.28

主要内容：预测

- 预测
- 习题

预测

♠ 主要内容见: Draper and Smith (1998). p.80-87

预测

- ♠ 回归的主要目的之一是用来预测。假定我们收集到数据 $(\mathbf{X}_i, \mathbf{Y}_i), 1 \leq i \leq n$. 然后建立线性回归模型:

$$\mathbf{Y}_i = \beta_0 + \beta_1 \mathbf{X}_i + \epsilon_i, \epsilon_i \sim iid N(0, \sigma^2).$$

其中 β_0, β_1 和 σ^2 是未知的参数。利用LS法，我们可以得到 β_0 和 β_1 的LSE分别为: b_0 和 b_1 .

- ♠ 当有新的 $x = x_0$ 时，我们要预测对应随机变量 y_0 的值。很明显，

$$\hat{y}_0 = b_0 + b_1 x_0. \quad (1)$$

- ♠ 由LSE的性质， $\mathbf{E}[b_0] = \beta_0, \mathbf{E}[b_1] = \beta_1$. 因此

$$\mathbf{E}[\hat{y}_0] = \beta_0 + \beta_1 x_0. \quad (2)$$

♠ \hat{y}_0 的方差为:

$$\text{Var}[\hat{y}_0] = \sigma^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (\mathbf{X}_i - \bar{X})^2} \right]. \quad (3)$$

这是因为:

$$\begin{aligned} \text{Var}[\hat{y}_0] &= \mathbf{E}[\hat{y}_0 - \mathbf{E}[\hat{y}_0]]^2 \\ &= \mathbf{E}[(b_0 + b_1 x_0) - (\beta_0 + \beta_1 x_0)]^2 \\ &= \mathbf{E}[(b_0 - \beta_0) + (b_1 - \beta_1)x_0]^2 \\ &= \mathbf{E} \left[(b_1 - \beta_1)(x_0 - \bar{X}) + \frac{1}{n} \sum_{i=1}^n \epsilon_i \right]^2 \\ &= \sigma^2 + \sigma^2 (x_0 - \bar{X})^2 / \sum_{i=1}^n (\mathbf{X}_i - \bar{X})^2. \end{aligned}$$

- ♠ 可以看出， $\text{Var}[\hat{y}_0]$ 随着 $(x_0 - \bar{X})^2$ 的增加而增加。因而， x_0 离 \bar{X} 越远，方差 $\text{Var}[\hat{y}_0]$ 越大。
- ♠ 注意 y_0 是在 x_0 处未来的观测(不知道具体的值)，我们用 \hat{y}_0 去预测 y_0 。我们现在感兴趣差：

$$y_0 - \hat{y}_0. \tag{4}$$

- ♠ 我们现在欲得到(4)中的均值和方差。注意到模型假设，有

$$y_0 = \beta_0 + \beta_1 x_0 + \epsilon_0, \epsilon_0 \sim N(0, \sigma^2), \epsilon_0 \text{ 与 } \epsilon_i \text{ 独立}, i = 1, \dots, n.$$



$$\mathbf{E}[y_0] = \beta_0 + \beta_1 x_0.$$

结合(2), 得到:

$$\mathbf{E}[y_0 - \hat{y}_0] = 0. \quad (5)$$

由此, (4)的方差为:

$$\begin{aligned} \text{Var}[y_0 - \hat{y}_0] &= \text{Var}[y_0] + \text{Var}[\hat{y}_0] \\ &= \sigma^2 \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{X})^2}{\sum_{i=1}^n (\mathbf{X}_i - \bar{X})^2} \right]. \quad (6) \end{aligned}$$

- ♠ 因为 σ^2 是未知的, 在实际应用中, 要用 S^2 代替(3)和(6)的 σ^2 .
- ♠ 由于未来的观测值 y_0 未必在真的直线 $y = \beta_0 + \beta_1 x$ 或者拟合直线 $y = b_0 + b_1 x$ 上。由于 $y_0 - \beta_0 - \beta_1 x_0$ 的方差为 σ^2 . 因此, $y_0 - \hat{y}_0$ 的方差是两部分 $\text{Var}[y_0]$ 和 $\text{Var}[\hat{y}_0]$ 的组合。

预测区间

- ♠ 因为 y_0 是在 x_0 处的新的观测值，所以 y_0 , \hat{y}_0 和 S^2 都是独立的。因此，下面的两个随机变量是独立的：

$$Z = \frac{y - \hat{y}_0}{\sigma \left[1 + \frac{1}{n} + \frac{(x - \bar{X})^2}{s_x^2} \right]^{1/2}}, W = \frac{(n-2)S^2}{\sigma^2},$$

其中 $s_x^2 = \sum_{i=1}^n (\mathbf{X}_i - \bar{X})^2$.

因为 y_0 和 \hat{y}_0 是独立的正态随机变量，故 $Z \sim N(0, 1)$.

$W \sim \chi_{n-2}^2$. 于是 $Z/(W/(n-2))^{1/2} \sim t_{n-2}$.

$$U_{x_0} = \frac{y_0 - \hat{y}_0}{S \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{X})^2}{s_x^2} \right]^{1/2}} \sim t_{n-2}. \quad (7)$$

♠ 给定 $1 - \alpha_0 \in (0, 1)$, 由7得到

$$P(|U_{x_0}| \leq t_{n-2}^{-1}(1 - \alpha_0/2)) = 1 - \alpha_0.$$

♠ 从而, 随机变量 y_0 介于两个随机变量

$$\hat{y}_0 \pm t_{n-2}^{-1}(1 - \alpha_0/2)S \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{X})^2}{s_x^2} \right]^{1/2}. \quad (8)$$

之间的概率是 $1 - \alpha_0$.

定义.

(8)中给出的随机区间称为 y_0 的系数为 $1 - \alpha_0$ 的预测区间。

- ♠ 请注意参数的置信区间和随机响应的预测区间的差别。在得到(8)中的所有观测值之后，(8)中的区间与置信区间有相同的解释，但要注意 y_0 是随机变量！！
- ♠ 关于设计点和预测区间进一步内容，请仔细阅读 Draper and Smith (1998) Applied Regression Analysis中p. 79-89的内容，特别是与Figure 3.1, 3.2 3.3有关的内容。这部分内容不在课堂讲解，但要求掌握。

习题

- ♠ Draper and Smith (1998) Applied Regression Analysis, p. 96-108中的J, K, T, AA