

《线性回归》 —线性回归(8)

杨 瑛

清华大学 数学科学系

Email: yangying@mail.tsinghua.edu.cn

Tel: 62796887

2019.04.04

主要内容: LSE的性质

- 设计矩阵列正交
- 有线性约束的LSE
- 其它专题: 广义最小二乘回归
- 其它专题: 问题
- 其它专题: 中心化和尺度化协变量
- 其它专题: Bayes估计
- 其它专题: 稳健估计

设计矩阵列正交

在线性模型

$$\mathbf{Y} = \mathbf{X}\theta + \epsilon$$

中，当设计矩阵 \mathbf{X} 表示为列的形式：

$$\mathbf{X} = (\mathbf{x}^{(0)}, \mathbf{x}^{(1)}, \dots, \mathbf{x}^{(p-1)}),$$

列向量是正交的。

♠ θ 的LSE有如下的表达式：

$$\begin{aligned}\hat{\theta} &= (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y} \\ &= \begin{pmatrix} (\mathbf{x}^{(0)'} \mathbf{x}^{(0)})^{-1} \mathbf{x}^{(0)'} \mathbf{Y} \\ (\mathbf{x}^{(1)'} \mathbf{x}^{(1)})^{-1} \mathbf{x}^{(1)'} \mathbf{Y} \\ \vdots \\ (\mathbf{x}^{(p-1)'} \mathbf{x}^{(p-1)})^{-1} \mathbf{x}^{(p-1)'} \mathbf{Y} \end{pmatrix}\end{aligned}$$

♠ 此时，

$$\hat{\theta}_j = \mathbf{x}^{(j)'} \mathbf{Y} / \mathbf{x}^{(j)'} \mathbf{x}^{(j)},$$

♠ 相当于 \mathbf{Y} 对单个变量 \mathbf{x}_j 做通过原点的回归 $\mathbf{E}[\mathbf{Y}] = \mathbf{x}^{(j)} \beta_j$.

有线性约束的LSE

♠ 考虑线性模型

$$\mathbf{Y} = \mathbf{X}\theta + \epsilon, \epsilon \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n),$$

其中 \mathbf{X} 是秩为 p 的 $n \times p$ 的设计矩阵。

- ♠ 有时要考虑约束条件： $\mathbf{A}\theta = \mathbf{c}$ ，其中 \mathbf{A} 是秩为 q 的 $q \times p$ 矩阵， \mathbf{c} 是 $q \times 1$ 的列向量。
- ♠ 利用Lagrange乘子法可以求解这个问题。上面的约束相当于 q 个约束： $\mathbf{a}_i^T \theta = c_i, (i = 1, \dots, q)$ ，其中 \mathbf{a}_i^T 是 \mathbf{A} 的行向量。
- ♠ 注意：

$$\sum_{i=1}^q \lambda_i (\mathbf{a}_i^T \theta - c_i) = \lambda^T (\mathbf{A}\theta - \mathbf{c}) = (\theta^T \mathbf{A}^T - \mathbf{c}^T) \lambda.$$

♠ 定义

$$L(\theta, \lambda) = \|\mathbf{Y} - \mathbf{X}\theta\|^2 + (\theta^T \mathbf{A}^T - \mathbf{c}^T)\lambda$$

♠ 关于 $L(\theta, \lambda)$ 求最小值，相当于求解：

$$\mathbf{A}\theta = \mathbf{c}, \quad (1)$$

$$-2\mathbf{X}^T\mathbf{Y} + 2\mathbf{X}^T\mathbf{X}\theta + \mathbf{A}^T\lambda = \mathbf{0}. \quad (2)$$

设 $\hat{\theta}_H$ 和 $\hat{\lambda}_H$ 表示上面方程组的解。

♠ 由(2)得

$$\begin{aligned} \hat{\theta}_H &= (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y} - \frac{1}{2}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{A}^T\hat{\lambda}_H \\ &= \hat{\theta} - \frac{1}{2}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{A}^T\hat{\lambda}_H, \end{aligned} \quad (3)$$

♠ 从(1),得到:

$$\mathbf{c} = \mathbf{A}\hat{\theta}_H = \mathbf{A}\hat{\theta} - \frac{1}{2}\mathbf{A}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{A}^T\hat{\lambda}_H.$$

♠ 由于 $(\mathbf{X}^T\mathbf{X})^{-1}$ 正定, 可以证明 $\mathbf{A}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{A}^T$ 是对称正定的, 因而是非奇异的。故有

$$-\frac{1}{2}\hat{\lambda}_H = [\mathbf{A}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{A}^T]^{-1}(\mathbf{c} - \mathbf{A}\hat{\theta})$$

带入(3), 得到

$$\hat{\theta}_H = \hat{\theta} + (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{A}^T[\mathbf{A}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{A}^T]^{-1}(\mathbf{c} - \mathbf{A}\hat{\theta}). \quad (4)$$

♠ 还要证明：在条件 $\mathbf{A}\theta = \mathbf{c}$ 之下， $\hat{\theta}_H$ 确实是 $\|\mathbf{Y} - \mathbf{X}\theta\|^2$ 的最小值点。

♠ 注意到：

$$\begin{aligned}
 \|\mathbf{X}(\hat{\theta} - \theta)\|^2 &= (\hat{\theta} - \theta)\mathbf{X}^T\mathbf{X}(\hat{\theta} - \theta) \\
 &= (\hat{\theta} - \hat{\theta}_H + \hat{\theta}_H - \theta)\mathbf{X}^T\mathbf{X}(\hat{\theta} - \hat{\theta}_H + \hat{\theta}_H - \theta) \\
 &= (\hat{\theta} - \hat{\theta}_H)\mathbf{X}^T\mathbf{X}(\hat{\theta} - \hat{\theta}_H) \\
 &\quad + (\hat{\theta}_H - \theta)\mathbf{X}^T\mathbf{X}(\hat{\theta}_H - \theta) \tag{5}
 \end{aligned}$$

$$= \|\mathbf{X}(\hat{\theta} - \hat{\theta}_H)\|^2 + \|\mathbf{X}(\hat{\theta}_H - \theta)\|^2, \tag{6}$$

(5)成立是因为由(3),

$$2(\hat{\theta} - \hat{\theta}_H)\mathbf{X}^T\mathbf{X}(\hat{\theta}_H - \theta) = \hat{\lambda}'_H\mathbf{A}((\hat{\theta}_H - \theta)) = \hat{\lambda}'_H(\mathbf{c} - \mathbf{c}) = 0. \tag{7}$$

♠ 从(6)得:

$$\begin{aligned}\|\mathbf{Y} - \mathbf{X}\theta\|^2 &= \|\mathbf{Y} - \mathbf{X}\hat{\theta}\|^2 + \|\mathbf{X}(\hat{\theta}_H - \theta)\|^2 \\ &= \|\mathbf{Y} - \mathbf{X}\hat{\theta}\|^2 + \|\mathbf{X}(\hat{\theta} - \hat{\theta}_H)\|^2 + \|\mathbf{X}(\hat{\theta}_H - \theta)\|^2\end{aligned}\quad (8)$$

在 $\|\mathbf{X}(\hat{\theta}_H - \theta)\|^2 = 0$ 时取得最小值, 即: $\mathbf{X}(\hat{\theta}_H - \theta) = 0$, 或者 $\theta = \hat{\theta}_H$ (因为 \mathbf{X} 的列是线性独立的, 列满秩)。

♠ 令 $\theta = \hat{\theta}_H$, 则得到有用的等式:

$$\|\mathbf{Y} - \mathbf{X}\hat{\theta}_H\|^2 = \|\mathbf{Y} - \mathbf{X}\hat{\theta}\|^2 + \|\mathbf{X}(\hat{\theta} - \hat{\theta}_H)\|^2. \quad (9)$$

或者, $\hat{\mathbf{Y}} = \mathbf{X}\hat{\theta}$, $\hat{\mathbf{Y}}_H = \mathbf{X}\hat{\theta}_H$, 直接得到

$$\|\mathbf{Y} - \hat{\mathbf{Y}}_H\|^2 - \|\mathbf{Y} - \hat{\mathbf{Y}}\|^2 = \|\hat{\mathbf{Y}} - \hat{\mathbf{Y}}_H\|^2. \quad (10)$$

其它专题: 广义最小二乘回归

- ♠ 广义最小二乘回归
考虑线性模型

$$\mathbf{Y} = \mathbf{X}\theta + \epsilon, \epsilon \sim N_n(\mathbf{0}, \sigma^2 \Sigma), \quad (11)$$

其中 \mathbf{X} 是秩为 p 的 $n \times p$ 的设计矩阵, Σ 是已知的 $n \times n$ 的正定阵, σ^2 未知。

- ♠ 对 Σ 做分解: $\Sigma = \mathbf{K}\mathbf{K}^T$, 可到新的线性模型:

$$\mathbf{K}^{-1}\mathbf{Y} = \mathbf{K}^{-1}\mathbf{X}\theta + \mathbf{K}^{-1}\epsilon, \mathbf{K}\epsilon \sim N_n(\mathbf{0}, \sigma^2 \mathbf{I}_n).$$

由此可以利用普通的LS得到 θ 的估计 θ_G .

- ♠ 细节详见: Seber and Lee (2003), p. 66-69.
- ♠ 模型(11)的参数 θ 也可以极小化 $\|\mathbf{Y} - \mathbf{X}\theta\|^2$ 得到 $\hat{\theta}$.
- ♠ 【作业】: 试比较 $\hat{\theta}_G$ 和 $\hat{\theta}$ 的性质, 试构造 σ^2 的两种估计。

其它专题：问题

♠ 考虑线性模型

$$\mathbf{Y} = \mathbf{X}\theta + \epsilon, \epsilon \sim N_n(\mathbf{0}, \Sigma), \quad (12)$$

其中 \mathbf{X} 是秩为 p 的 $n \times p$ 的设计矩阵, Σ 是未知的 $n \times n$ 正定阵。

♠ θ 可以极小化 $\|\mathbf{Y} - \mathbf{X}\theta\|^2$ 的 θ 的LSE。

♠ 现在的问题：如何估计矩阵 Σ ，并对所得到的估计研究其性质。

其它专题: 中心化和尺度化协变量

- ♠ 为得到回归系数的合理解释, 有时需要对协变量进行中心化或者尺度化。
- ♠ 结合前面关于回归系数的解释, 阅读Seber and Lee (2003), p. 69–72.

其它专题: Bayes估计

- ♠ 需要对线性模型中的参数 θ 或者 σ^2 添加先验分布, 然后做估计或者推断。
- ♠ 想一下: 如何给这些参数添加先验分布?
- ♠ 阅读Seber and Lee (2003), p. 73-77.

其它专题: 稳健估计

- ♠ 后面有ppt简述这个问题。
- ♠ 亦可阅读Seber and Lee (2003), p. 77-95.

【第十二讲】